DESENVOLVIMENTO ASSISTIDO POR IA · BLOCO 6

Produtividade real, medição e uso em time

6

Sábado, 24/10/2026 · 14h às 17h

Ferramenta: Claude Code · modo manual por padrão

Pós-Graduação em Engenharia de Software e IA · CESAR School

CESAR

ABERTURA

Vocabulário do bloco

baseline	medida de antes, para comparar
guardrail	métrica que não pode piorar
intervalo de confiança	faixa plausível do efeito
RCT	ensaio controlado aleatorizado
viés de seleção	amostra que não representa o todo

Goodhart	métrica que vira meta deixa de medir
SPACE	cinco dimensões da produtividade
DORA	pesquisa e métricas de entrega
lead time	tempo do commit até a produção
retrabalho (rework)	mudança refeita logo depois

Quanto mais produtivo você ficou com IA? Como você sabe?

Responda no chat

CESAR

ABERTURA

Agenda do bloco

Hoje · 24/10

14h00
Exposição: evidência, medição, time e automação

15h00
Pausa

15h10 às 16h25
AV1.6 · medir o seu contexto e escolher o que automatizar

16h25
Casos e fechamento da disciplina

Disciplina · 6 blocos

B1 · 16/10
Modos e ambiente

B2 · 17/10
Escopo e refatoração

B3 · 17/10
Testes e docs

B4 · 23/10
Legado

B5 · 24/10
Revisão e segurança

B6 · agora
Produtividade e time

EVIDÊNCIA

Por que estudos sérios chegam a resultados opostos?

Tarefa, contexto, ferramenta e forma de medir mudam o resultado.

EVIDÊNCIA

Peng et al. (2023): tarefa fechada, ganho grande

55,8%

mais rápido para concluir a tarefa com Copilot

Tarefa: escrever um servidor HTTP em JavaScript.

TIPO Experimento controlado · tarefa pequena e isolada · ferramenta da época

EVIDÊNCIA

METR (2025): especialistas em repositórios maduros

+19%

de tempo nas tarefas com IA

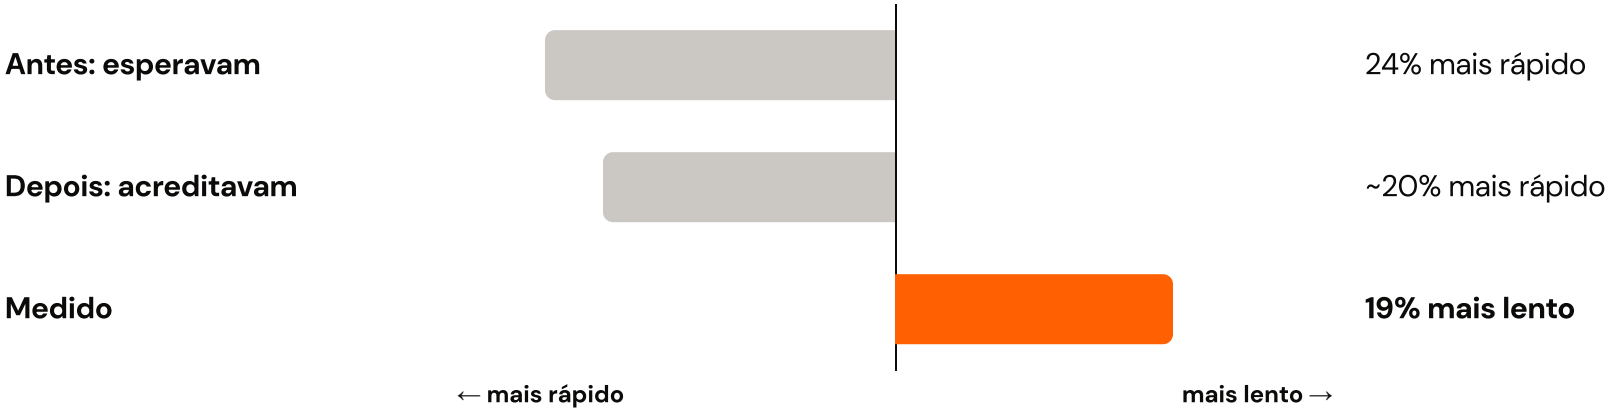
Intervalo: +2% a +39%

16 desenvolvedores experientes, 246 tarefas em seus próprios repositórios.

TIPO RCT · amostra pequena · ferramentas do início de 2025

EVIDÊNCIA

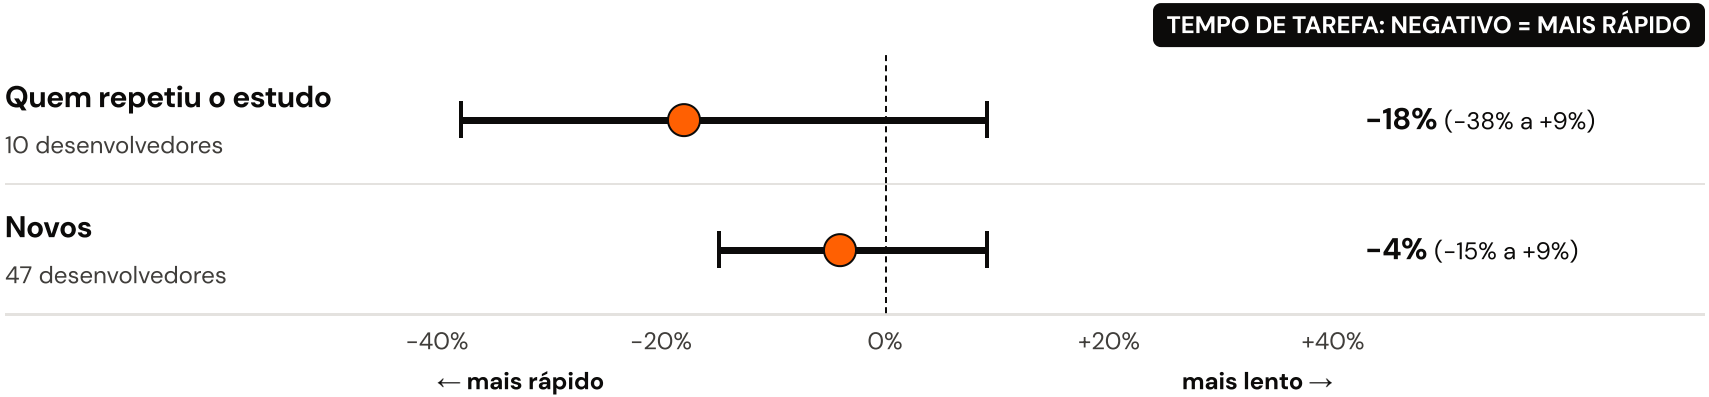
A percepção divergiu da medição



EVIDÊNCIA

METR (fev/2026): nova medição, mais difícil

57 desenvolvedores, 143 repositórios, mais de 800 tarefas. Os intervalos cruzam zero.



O QUE A METR CONCLUIU

Provavelmente os desenvolvedores estão mais acelerados em 2026, mas os dados são evidência fraca sobre o tamanho do ganho, por efeitos de seleção

O método está sendo redesenhado.

EVIDÊNCIA

DORA 2025: o sistema, não só a tarefa

~90%
usam IA

2h
mediana de uso por dia

80%+
percebem ganho

~30%
confiam pouco ou nada no código gerado

IA associada a **mais vazão de entrega** e a **mais instabilidade**. Cerca de 5.000 profissionais.

TIPO Levantamento · autorrelato e correlação

EVIDÊNCIA

Google (Nikolov et al.): migrações em escala

~50%

de redução de tempo, estimativa dos engenheiros

Com pipeline de descoberta, validação e revisão.

TIPO Relato de experiência em contexto excepcional

COMO LER

Oito moderadores explicam a divergência

1. Tamanho e fechamento da tarefa
2. Familiaridade com o código
3. Maturidade do repositório
4. Qualidade dos testes
5. Custo de revisão
6. Geração da ferramenta e habilidade
7. Como se mede
8. Seleção e substituição de tarefas

HIPÓTESES

Por que a IA pode atrasar o especialista

Tempo especificando, esperando e corrigindo sugestões parcialmente certas. Quem conhece o repositório gasta pouco tempo digitando.

HIPÓTESE Mecanismo plausível; meça no seu contexto.

COMO LER

Como ler um estudo de produtividade

1. Desenho
2. Amostra
3. Tarefa
4. O que foi medido
5. Incerteza (o intervalo cruza zero?)
6. Versão da ferramenta e data
7. Quem financiou
8. O que eu precisaria medir no meu contexto

O QUE MEDIR

Comece pela pergunta, não pela métrica



GQM: Goal, Question, Metric

O QUE MEDIR

Famílias de métricas

Família	Exemplos
Entrega (DORA)	Frequência de deploy, lead time, taxa de falha, tempo de recuperação
Fluxo e revisão	Tempo até a primeira revisão, tamanho do PR
Qualidade	Retrabalho, defeitos escapados, reverts
Experiência do desenvolvedor	Carga cognitiva, satisfação (pesquisa)
Específicas de IA	Taxa de aceitação, % de código por IA: **mostram uso, não valor**

O QUE MEDIR

SPACE: cinco dimensões

Dimensão	Exemplo	Distorção com IA
Satisfaction	Satisfação e carga cognitiva	Entusiasmo inicial infla a percepção
Performance	Falha de mudança, retrabalho	Mais código não é mais resultado
Activity	Commits, PRs, linhas	A IA infla o volume
Communication	Tempo até a primeira revisão	A revisão vira gargalo
Efficiency	Lead time, fluxo sem interrupção	Espera por revisão some do número

REGRA Capture ao menos três, incluindo uma de percepção.

O QUE MEDIR

Scorecard de exemplo para um piloto

Dimensão	Indicador	Papel
S	Pesquisa curta de carga cognitiva	Percepção
P	Falha de mudança e retrabalho	**Guardrail**
A	Nº de PRs	Só contexto
C	Tempo até a primeira revisão	Acompanhamento
E	Lead time	**Métrica primária**

O QUE MEDIR

Desenho mínimo de uma medição honesta

1. Pergunta e decisão
2. Métrica primária e guardrail
3. Baseline de 4 a 8 semanas
4. Comparação (antes/depois, escalonada ou por tarefa)
5. Período
6. Risco de manipulação declarado
7. Critério de revisão

MÁXIMA Sem baseline não existe ganho, existe impressão.

GOODHART

Quando a métrica vira meta

Meta	Comportamento	Contramedida
Sugestões aceitas	Inchaço	Parear com retrabalho e tamanho do diff
Nº de PRs	PRs minúsculos	Medir lead time de ponta a ponta
Cobertura	Testes tautológicos	Escore de mutação e sabotagem
% de código por IA	Uso forçado	Não usar como meta
Velocidade	Estimativas infladas	Comparar com a entrega real

GOODHART

Princípios contra a manipulação

1. Pares de métricas (velocidade e qualidade)
2. Medir times, não pessoas
3. Misturar com avaliação qualitativa
4. Declarar de antemão como a métrica seria gamificada

USO EM TIME

Combinado de time: zonas de risco

Zona	Exemplos	Como entra
VERDE	Docs, scaffolding, testes de funções puras	Direto, com autorrevisão e CI
AMARELA	Lógica de negócio, integrações	Revisão de par e checklist
VERMELHA	Autenticação, pagamentos, migrações, infra, segredos	Par obrigatório, revisão de segurança, agente restrito ou vedado

USO EM TIME

Outros pontos do acordo

- [ ] Quem revisa o quê e em quanto tempo
- [ ] Declarar participação de IA
- [ ] O que fazer com dependência suspeita ou injeção de prompt
- [ ] Limite de PRs de IA por revisor
- [ ] Ferramentas aprovadas e tratamento de dados
- [ ] Garantir que iniciantes entendem o que enviam

USO EM TIME

DORA AI Capabilities Model: sete capacidades

1. Posição clara sobre IA
2. Ecossistema de dados saudável
3. Dados internos acessíveis à IA
4. Controle de versão forte
5. Lotes pequenos
6. Foco no usuário
7. Plataforma interna de qualidade

Tradução livre.

USO EM TIME

A IA amplifica o que o time já é

Em time com testes frágeis e revisão sobrecarregada, amplifica a fragilidade.

AUTOMAÇÃO

Escada de automação

01

Prompt reutilizável versionado

02

Comando com parâmetros

03

Execução não interativa em script

04

Etapa em CI com permissões mínimas

AUTOMAÇÃO

Quando vale automatizar

Critério	Pergunta
Frequência	Acontece toda semana?
Custo atual	Quanto tempo leva hoje?
Verificabilidade	Dá para checar a saída de forma barata?
Variabilidade	Cada caso é diferente do anterior?
Raio de impacto	O que quebra se sair errado?
Custo de manter	Quem conserta quando mudar?

AUTOMAÇÃO

Candidatas boas e ruins

BOAS

Descrição de PR a partir do diff

Notas de versão

Triagem de falhas de CI

Resumo de breaking changes

RUINS

Qualquer coisa em zona vermelha

Decisões que exigem contexto que o agente não tem

Tarefas sem verificação barata

AUTOMAÇÃO

A verificação que a automação exige

- [ ] Checagens determinísticas na saída
- [ ] Saída como proposta, não como ação
- [ ] Orçamento e tempo-limite
- [ ] Exemplos de referência
- [ ] Permissões mínimas, sem segredos no passo do agente
- [ ] Log e responsável

AUTOMAÇÃO

Risco de CI: conteúdo não confiável

ALERTA

O texto de um PR, diff ou issue pode conter instruções maliciosas.

Não rode agente com segredos ou escrita sobre PRs de forks.

Separe o passo que lê do passo que publica.

AUTOMAÇÃO

Exemplo ilustrativo: resumo de PR em dois jobs

```yaml
# Ilustrativo
name: resumo-de-pr
on: { pull_request: { types: [opened, synchronize] } }
permissions: { contents: read }
jobs:
  resumir:
    if: github.event.pull_request.head.repo.full_name == github.repository   # sem forks
    steps:
      - run: git diff origin/${{ github.base_ref }}...HEAD > diff.patch
      - run: ./scripts/agente-nao-interativo.sh --somente-leitura --limite-custo 1 < diff.patch > resumo.md
  publicar:
    needs: resumir
    permissions: { pull-requests: write }     # só este job comenta
    steps: [ { run: gh pr comment ... --body-file resumo.md } ]
```

Meça o seu contexto e escolha o que automatizar

1. Desenhe a medição: pergunta e decisão, métrica primária, guardrail, baseline, período e método, confundidores, **risco de manipulação**
2. Aponte uma tarefa recorrente a automatizar e a verificação que ela exigiria

Use seus registros AV1.1 a AV1.3 como baseline em miniatura · **Tempo:** 45 min

ONDE

exercicios/aula-6/README.md

exercicios/aula-6/template-registro.md

AV1.6: modelo e exemplo preenchido

EXEMPLO · NÃO COPIE

```
PERGUNTA      O agente para atualizar dependências reduz o tempo entre a correção de segurança e o merge,
              sem aumentar reversões?
DECISÃO       Continuar, expandir ou restringir o uso
PRIMÁRIA      Mediana de dias da divulgação da CVE até o merge
GUARDRAIL     Taxa de revert e falhas de CI pós-merge
BASELINE      8 semanas anteriores, pelo histórico do repositório
RISCO         Aceitar atualizações sem revisar breaking changes para reduzir o tempo
VERIFICAÇÃO   Conferir com o changelog oficial e rodar a suíte completa
```

Janela: 15h10 às 16h25

AV1.6 em salas: 45 minutos

Trabalho	**individual, com apoio do grupo**
Escolham	**1 caso para apresentar**
Fim da janela	**16h25**

VOLTEM ÀS

16h10

Faltam 71:22

CESAR

Apresentação de 4 ou 5 casos

Pergunta · métrica · baseline · risco de manipulação · tarefa a automatizar

FECHAMENTO DA DISCIPLINA

1. O modo errado custa mais que não usar IA.
2. Escopo declarado separa refatoração de reescrita.
3. Teste que não falharia é enfeite.
4. Em legado, a IA acelera a leitura e não substitui a conferência.
5. Quem aprova o merge responde pelo código.
6. Sem baseline não existe ganho, existe impressão.

FECHAMENTO

Ponte e entrega final

Becker et al. (2025) e atualização da METR (24/02/2026).
arXiv 2507.09089

Peng et al. (2023).
arXiv 2302.06590

DORA (2025). State of AI-assisted Software Development.
dora.dev

Próxima disciplina: Prompting Técnico, Especificação e Contexto (começa em 06/11).

AV3

Até 30/10, 23h59

avaliacoes/av3/README.md

AV2

Até 21/10, 23h59

avaliacoes/av2/README.md

github.com/jamissonfreitas/repo_alunos_d12_esia

CESAR